第 66 屆國立暨縣（市）公私立高級中等學校第 6 區科學展覽會
作品說明書

科 別： 電腦與資訊科學

組 別：高級中等學校組

作品名稱： Musicbrain-結合多標籤分類與可解釋性之 AI 生成音樂識別模型

關鍵詞：AI 生成音樂、音樂辨識、多標籤可解釋性

摘要

隨著生成式人工智慧（Gen AI）技術的爆發式增長，數位音樂產業正面臨前所未有的版權歸屬與倫理挑戰。本研究提出 **MusicBrain** 架構，是一專為 AI 生成音樂檢測（Machine-Generated Music Detection, MGMD）設計之端到端深度學習模型。本模型不僅致力於高精度的分類（區辨人類與 AI），更前瞻性地整合多標籤分類技術與可解釋性人工智慧（XAI）。透過將視覺領域之「風格歸因」概念遷移至時頻域的鋼琴捲簾（Piano Roll）分析，MusicBrain 能夠精準解構音訊中的曲風特徵與作曲家指紋，為複雜的生成式音訊提供具備物理意義的判讀依據。

壹、前言(含研究動機、目的、文獻回顧)

一、研究動機

隨著生成式 AI 技術的跨越式發展，音樂創作的門檻已大幅降低，然而這股便利性卻對現行法律框架帶來了嚴峻挑戰。根據近期數據顯示，音樂串流平台上的 AI 生成垃圾曲目（AI spam tracks）數量急遽攀升，過去 12 個月內已有超過 7,500 萬首遭刪除（Spotify, 2025）；統計至 2025 年 12 月，平台上 AI 生成音樂的上傳佔比將達到 34%（每日約 50,000 首）（Deezer & Ipsos, 2025）。

依據台灣《著作權法》第 10-1 條（中華民國經濟部智慧財產局, 2023）規定：*”著作權保護之客體僅限於具體的「表達」，而不及於其所傳達之「思想、程序、製程、系統、操作方法、概念、原理、發現」”*。在音樂實務中，這意味著 AI 若僅是模仿特定作曲家的「風格」或「創作思想」，在法律層面上往往難以被認定為侵權，形成版權保護的灰色斷點 。然而，當 **AI 透過深度學習模型（如 Transformer 架構）對受保護作品進行高細節的特徵提取與重組時，其產出往往涉及「非法重製」或「改作」的模糊邊界** 。因此，**建立一套能精準區分「模仿思想」與「重製細節」的檢測機制，對於維護原創者權益及釐清法律責任具有極高的迫切性** 。

相較於視覺影像的直觀性，音樂特徵（如節奏脈動、和弦進行、音色微動）具有更強的隱蔽性，一般大眾難以單純透過感官直接辨識其與訓練數據的相似度。因此，建立一套透明、可解釋且可追溯的分析機制，對於保障人類原創者的權益以及建立健康的產業秩序至關重要。

二、研究目的

1. **AI 生成判定**：開發能精確區別 AI 生成音訊與人類原創作品的識別機制，特別針對具有高擬真度的 LLM 生成模型（如 MusicGen）。
2. **多維度風格辨識**：運用多標籤分類（Multi-label Classification）技術，突破單一分類的限制，同步標記樣本中所蘊含的多重音樂風格與細膩編曲特徵。
3. **歸因可解釋性**：透過辨識權重分布，將模型的決策依據予以量化分析，具體揭示模型在判斷過程中所依賴之音樂特徵。

三、文獻回顧

（一）多標籤分類與可解釋性模型

- **多標籤分類**：在分析音樂時，單一標籤（例如「搖滾」）通常不夠用，因為一首曲子可能同時具有多種特徵。所以我們使用了多標籤分類技術，讓模型能同時標記多種音樂屬性，更能貼近現實的複雜音樂。
- **解釋性模型：**為了讓模型的判斷過程「看得見」，我們採用了 FM-G-CAM 這個方法。這就像是給模型的決策過程一個權重地圖，讓研究人員知道模型是根據哪些音樂特徵來做出判斷的。

（二）技術參考

本研究針對 AI 生成音樂檢測（MGMD）任務，整合了跨領域的技術路徑。首先，在「風格歸因（Style Attribution）」方面，本研究借鑒了 ArtBrain 套件（Silva 等人, 2024），本研究創新之處在於將原屬於影像「像素空間」的分析概念，遷移至音訊的「時頻空間」。透過將音訊轉化為具備物理意義的鋼琴捲簾（Piano Roll），模型能如同掃描圖像般捕捉作曲家的「指紋」特徵。

為增強模型針對音樂的長距離時序依賴性，本研究參考了音訊頻譜 Transformer（Audio Spectrogram Transformer, AST）（Gong 等人, 2021）與卷積循環神經網路（CRNN）的優點。

貳、研究設備及器材

硬體設備：

- 筆記型電腦
  - 處理器 CPU：11th Gen Intel(R) Core(TM) i5-11300H @ 3.10GHz
  - 顯示卡 GPU： Intel(R) Iris(R) Xe Graphics
- 伺服器
  - 處理器 CPU：Intel(R) Xeon(R) Gold 5118 CPU @ 2.30GHz
  - 顯示卡 GPU：Nvidia Quadro RTX 5000(兩張)

軟體環境：

本研究之實驗環境建構於 Ubuntu 22.04 LTS 操作系統，使用 Python 3.10 作為主要開發語言。深度學習框架採用 PyTorch 2.1 搭配 CUDA 11.8 以進行伺服器 GPU 加速訓練與推理。在音訊與資料處理方面，使用 Librosa（McFee 等人, 2015） 進行時頻特徵提取，並透過 pretty_midi（Raffel & Ellis, 2014）處理 MIDI 檔案與鋼琴捲簾矩陣（Piano Roll）之間的格式轉換。

參、研究過程或方法

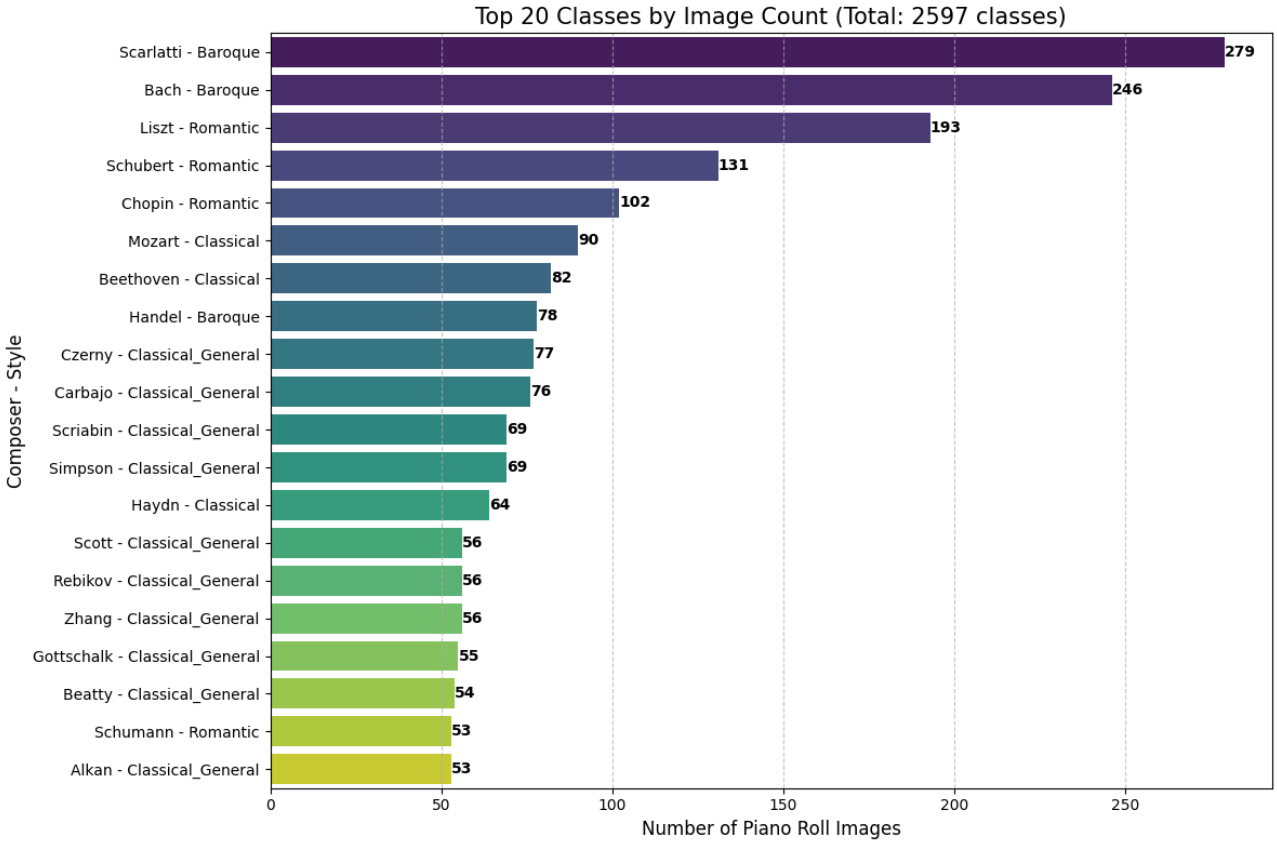
一.資料處理：

(一)資料集來源：

為了確保實驗結果的可靠性並構建具挑戰性的對抗樣本，本研究選用了以下作為實驗數據：

1. 人類原創組 (GiantMIDI-Piano)：

這是目前規模最大、標籤最完整的古典鋼琴 MIDI 資料集之一，包含 10,855 位作曲家的 168,037 首 MIDI 檔案（Yu 等人, 2020）。本研究選取數量最多的 20 組「Composer-Style」作為標籤，每組各取 50 首，確保數據平衡。



2.AI 生成實驗組 (MusicGen)：

作為對照組，本研究選用 Meta 發布的 MusicGen 模型（Copet 等人, 2023）。為了測試模型對不同生成能力的檢測效果，使用了兩組參數設定（Melody 3.3B 與 Large 3.3B），並使用與人類組相同的提示詞（Prompt）進行生成，例如：

> Prompt: "*Compose a piece of music in the style 'Classical_General', inspired by Charles-Valentin Alkan.*"

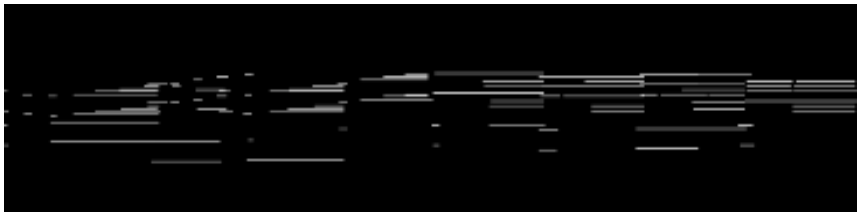
(二)資料轉換與視覺化處理

本研究基於「解釋性視覺化」原則，考量模型訓練效率與特徵呈現，決定將音訊資料轉化為

具備高度觀察性的矩陣格式。在音樂資訊檢索（MIR）領域中，本研究評估了以下兩種主流特徵表示法：

- **梅爾時頻譜 (Mel Spectrogram)：** 透過短時距傅立葉變換（STFT）獲取頻譜資訊，並映射至模擬人類聽覺感知的非線性「梅爾刻度」（Mel Scale）。雖能精準還原人耳對音高的感知，但其生成高度依賴原始音訊（Audio）品質。
- **鋼琴捲簾 (Piano Roll)：** 將 MIDI 資訊映射至二維矩陣，其 Y 軸代表 128 個 MIDI 音高（Pitch），X 軸代表時間序列（Time），並以像素亮度（0-255）表徵音符力度（Velocity）。此方法能直觀且精確地記錄樂譜特徵。

此外由於本研究採用之資料集來源為 MIDI 格式，若欲生成梅爾時頻譜，必須先將 MIDI 轉檔為音訊格式。然而，MIDI 轉檔過程需經過「音色庫」（SoundFont，如 A320U.sf2 或 GeneralUser GS）之合成，**不同音色庫會導致頻譜特徵產生非實驗預期的變異與偏誤**。



為了排除音色庫不統一所造成的干擾，並確保實驗的可重複性與數據一致性，本研究最終決議跳過音訊合成步驟，**直接採用鋼琴捲簾作為模型輸入與視覺化媒材**，以保留最原始、無偏差的樂譜資訊。

(三)資料強化 (Data Augmentation)：

鋼琴捲簾相較於圖片有著更高的時間連貫性及音域-位置強烈相關，因此傳統圖片的資料強化方式並不適用於鋼琴捲簾。

- **高斯雜訊（Gaussian noise）：**
  在圖像辨識領域中，高斯雜訊是一個很好的資料強化方式，可以避免模型針對特定像素做判斷，但是在鋼琴捲簾上，高斯雜訊相當於隨機按琴鍵，可能會破壞和聲含音樂的和諧性，導致音樂結構破壞。
- **圖像翻轉(Spin/flip)：**

  此方法會導致原始音訊出現顛倒播放或是出現高低音翻轉，完全毀壞音樂的音域與連貫性，導致模型無法實際學習音樂家的作曲風格資訊。

由於合成資料集資料數量在進行複雜的風格辨識是遠遠不夠的，因此我們採用了特殊的資料強化方式增加資料的變化性以及模型在學習得泛化程度，包含：

1. **節奏變速 (Tempo Scaling)**：
   透過對鋼琴捲簾的 X 軸（時間軸）進行寬度縮放（0.8 倍至 1.2 倍），以模擬不同演奏者之演奏速度差異。
2. **力度縮放 (Velocity Scaling)**：
   將整體張量（Tensor）數值乘上隨機係數（0.7 至 1.3），避促使其學習力度之相對變化。
3. **八度平移與移調 (Octave Transposition)**：
   採用精確的八度平移（即 **±12** 個半音）疊加微調（**±5** 個半音），迫使模型學習相對音程關係而非絕對音高。
4. **隨機漏音 (Note Dropout)**：
   隨機將圖像中 5% 的非零像素歸零，以模擬人類演奏複雜和弦時，因觸鍵力度過輕或收音問題而導致未能正確觸發 MIDI 訊號之漏音現象。

二.實驗設計

下面將詳細說明我們設計的音樂辨識模型，並說明架構與訓練方式：

CRNN(CNN+LSTM)+Transformer 模型：

核心模組詳述 (Detailed Module Description)

本研究建構了一套「時序雙頭 CRNN + transformer」（Temporal Dual-Head CRNN + Transformer），不同於先前的「時序雙頭 transformer」，本模型結合了一維卷積神經網路（1D CNN）的高效降採樣能力、雙向長短期記憶網路（Bi-LSTM）的長距離序列覆蓋優勢，以及 Transformer 處理全局音樂資訊邏輯的強大機制。模型以端到端（End-to-End）的方式，將原始時鋼琴捲簾轉換為 3 個合成來源與 21 個作曲家-風格(第 21 類為"無特徵"除錯)的雙頭預測結果。

架構概述 (Architecture Overview)

模型的前向傳播流程主要由特徵提取、時序建模與分類輸出三個階段構成：

1. **一維卷積特徵提取與極致時間壓縮：**
   前端在移除單一通道維度後，採用一層自訂的一維卷積區塊（Conv1d）。此階段最核心的設計在於其「完全保留音高與高效的時間壓縮」策略：模型將 128 維的音高頻率直接作為輸入通道數，以保留最高解析度的頻率物理特徵；同時，將池化步幅皆設定為 10（對應現實音樂的 0.1 秒），使時間軸被大幅壓縮了 10 倍。隨後搭配批次正規化（BatchNorm1d）與 GELU 激活函數，有效降低後續 LSTM 與 Transformer 的運算負擔。

2. **特徵重塑與序列化 ：**
   為了將其銜接至後續的時序模組，模型將張量進行轉置（Transpose），形成符合 RNN 與 Transformer 要求的 (Batch, Time, d_model) 序列格式。

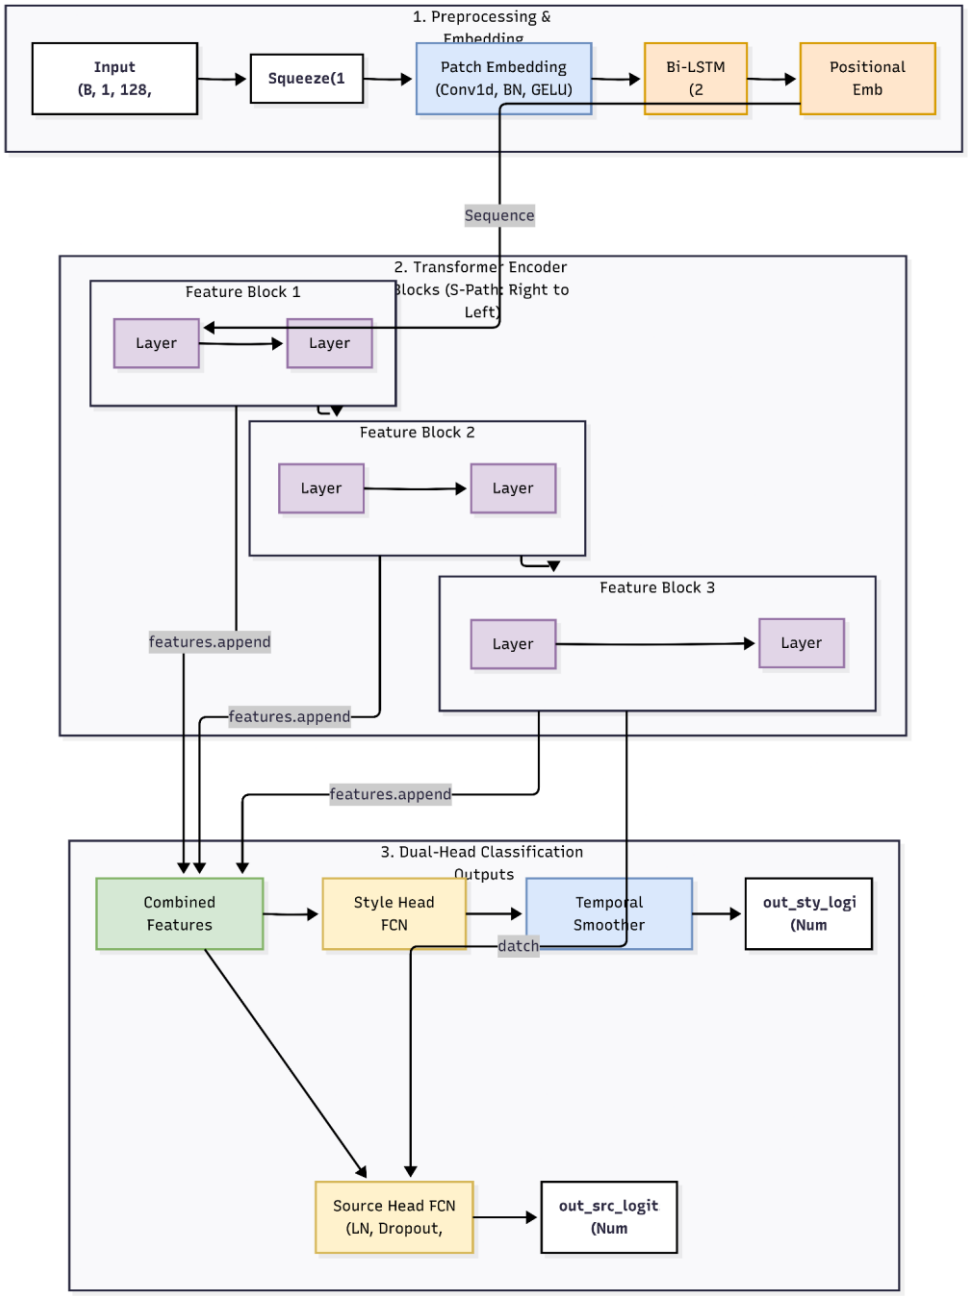
3. **複合時序建模 ：**
   序列特徵隨後進入結合了 RNN 與自注意力機制的複合架構中。

   - **雙向 LSTM 預處理**：特徵先進入 2 層的 Bi-LSTM 網路，為模型提供穩健的初步長距離時間覆蓋。
   - **多層 Transformer 編碼器**：注入位置嵌入（Positional Embedding）序列進入 6 層的 Transformer 編碼器。模型具備「多尺度特徵提取」邏輯，在運算過程中保留第 2、4、6 層的輸出，作為後續分類層輸入資料，以捕捉不同深度的語義表徵。

4. 雙頭全連接分類器與時序平滑 (Dual-Head Classifier & Temporal Smoothing)

為了滿足多任務學習需求並抑制過擬合風險，模型設計了獨立的雙頭決策層：

- **音源分類頭 (Source Head)**：接收 Transformer 最後一層的輸出。透過線性層直接映射至最終的 3 個音源類別。
- **風格分類頭 (Style Head)**：將前面保留的三層多尺度特徵在深度維度上拼接，經過 LayerNorm 及多層非線性映射，輸出 21 個作曲家-風格類別。
- **Logits 時序平滑**：在風格預測的最後階段，模型額外加入一層一維卷積（`kernel_size=5, padding=2`）作為時序平滑器（Temporal Smoother），確保相鄰時間步的預測結果更加穩定連貫。



CRNN(CNN+LSTM)+Transformer 模型訓練方式：

第一階段訓練-序列級別預測:

- 模型引入 Focal Loss 為解決風格歸因相對合成檢測較難分類的問題。針對 Style 任務實作了 `FocalLoss(gamma=2.0)`。這能讓模型降低簡單樣本的權重，專注於預測錯誤的困難樣本。
- **序列級別預測（File-level Prediction）**：資料集設定了最大序列長度 `MAX_SEQ_LEN = 2000`。模型輸出時間維度的機率分佈後，將機率在時間維度上取平均，最終決定整首曲子的類別。
- **梯度裁剪（Gradient Clipping）**：使用 `clip_grad_norm_` 將梯度最大值限制在 1.0，防止 Transformer 訓練初期常見的梯度爆炸問題。

第二階段訓練-frame by frame 預測:

此階段進行 finetune，將模型對於單標籤的輸出頭換成逐幀(frame by frame)的辨識格式。

- **特殊資料處理:**
  - 將鋼琴捲簾裁切成碎塊(最短至少為 100pixel，即 1 秒)，再傳接成 2000pixel 寬的長曲
  - 重新對鋼琴捲簾進行逐幀的標籤
- **優化器與學習率排程：**
  - 使用 `AdamW` 優化器，並將基礎學習率（Learning Rate）調低至 1e-4，以防破壞已經學好的底層特徵。
  - 搭配 `SequentialLR` 組合排程器：前 2 個 Epoch 進行 Warmup（學習率從極小線性爬升），之後依照 Cosine 曲線平滑下降，幫助模型在後期收斂到最佳解。
  - 設定 Loss 權重：定義 `ALPHA= 1.0(Source)`與 `BETA= 2.0(style)`。

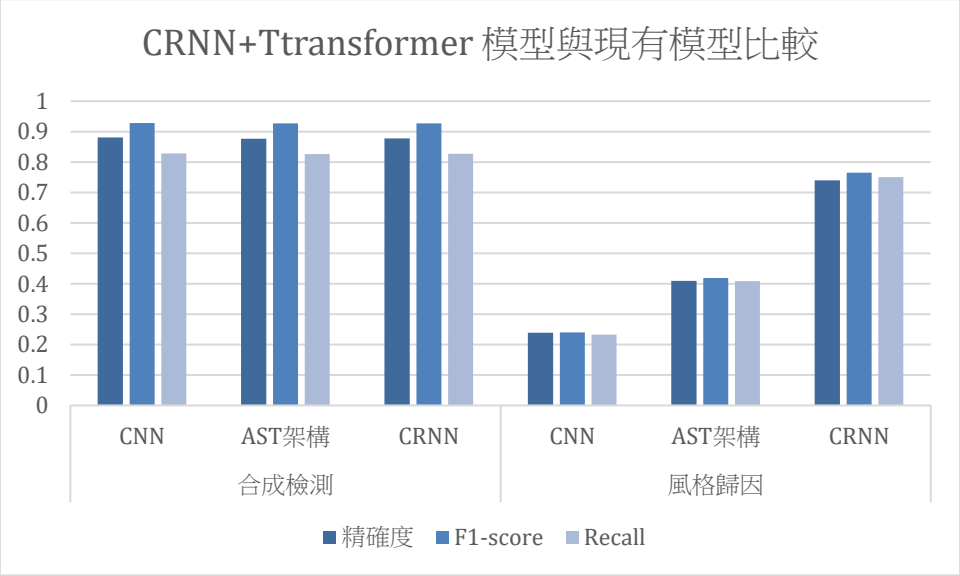
肆、研究結果

我們使用了同樣的資料集與資料前化方式分別訓練了兩組常見的音樂辨識模型架構，一組為基礎的 CNN 辨識模型，另一組為 AST 架構的音樂辨識模型，並比較三個模型在來源檢測和風格歸因的表現：

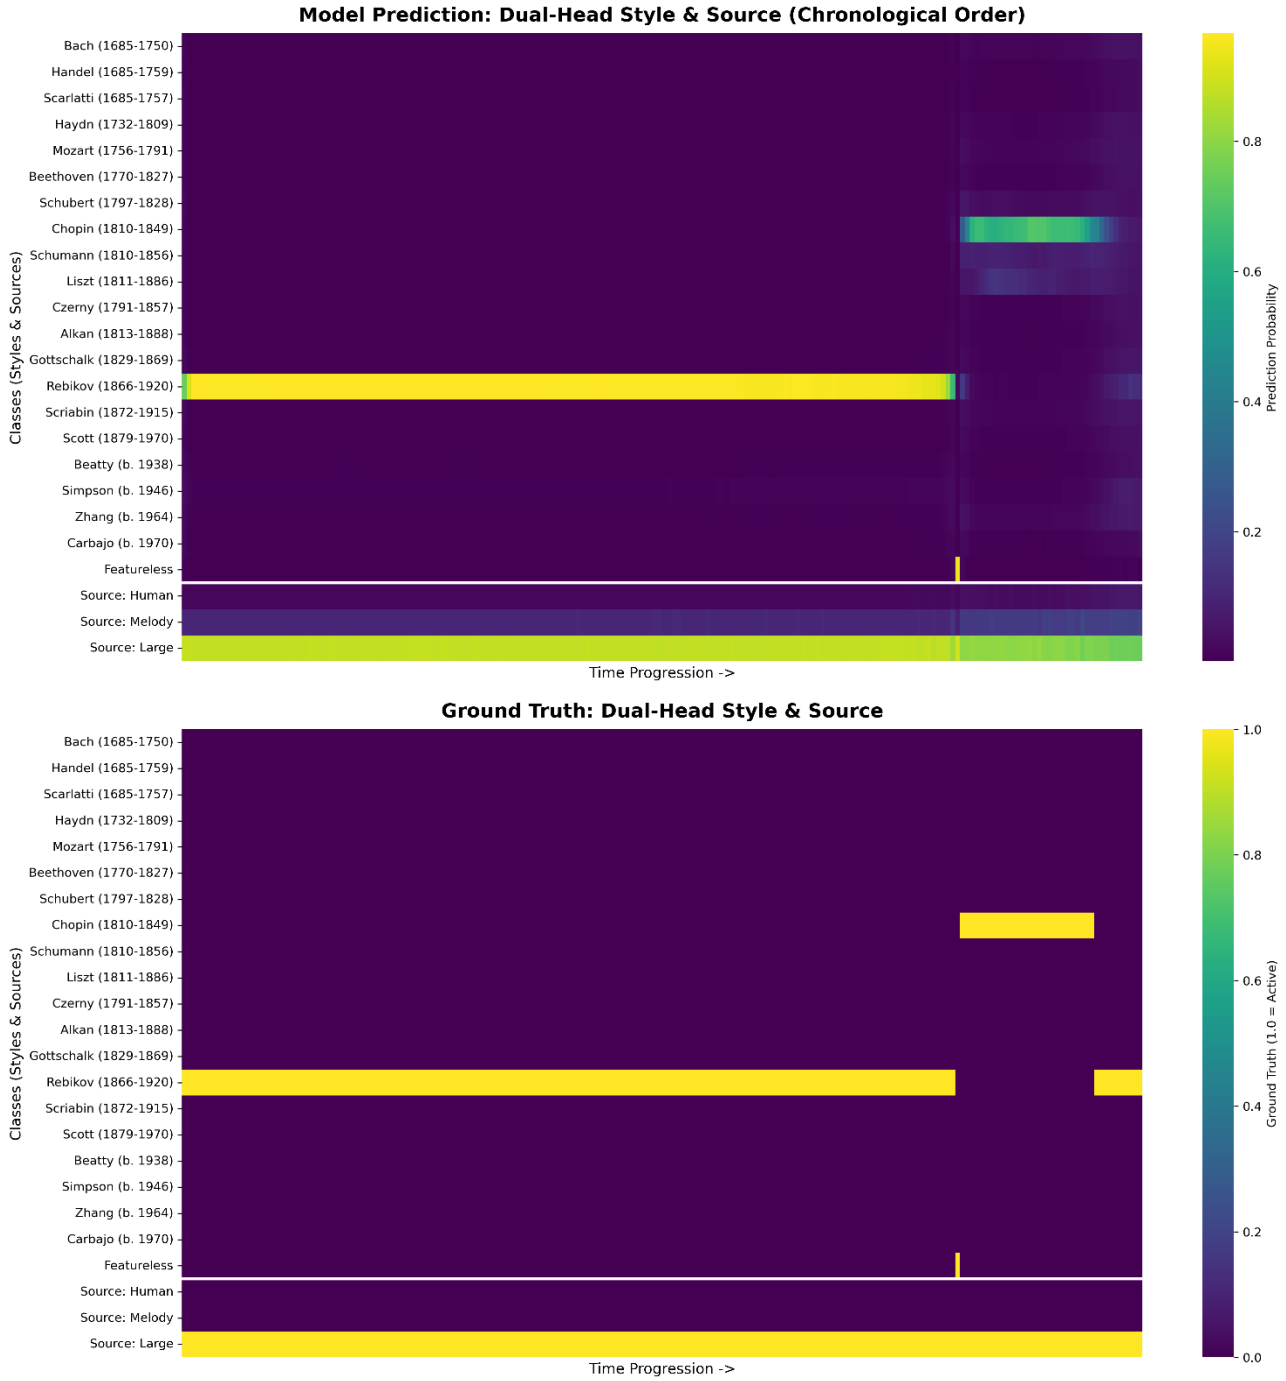
	合成檢測			風格歸因		
	CNN	AST	CRNN	CNN	AST	CRNN
精確度	**0.881**	0.876	0.878	0.2391	0.4098	**0.7396**
F1-score	**0.928**	0.927	0.927	0.2404	0.4193	**0.7653**
Recall	**0.828**	0.826	0.827	0.2330	0.4085	**0.7507**

從整體數據可以明顯看出，這兩個任務的難度有著巨大的落差：

- **合成檢測(Source，3 類)**：這是一個相對簡單的任務。三個模型都能達到 82% 以上的 F1 分數，且差異不大 。這暗示了區分「人類創作」、「MusicGen Large」與「MusicGen melody」之間的底層音訊或樂理特徵差異較為明顯，模型容易抓到分類規律，但是分辨極限約在於 90%左右，可能為相同的音樂旋律結構重複出現導致模型誤判或無法分辨。
- **作曲家與風格歸因 (Composer-Style，20/21 類)**：這是一個極具挑戰性的任務。不僅分類數量大幅增加（20/21 類），且不同古典作曲家（如 Mozart 與 Haydn，或 Chopin 與 Liszt）之間的風格邊界往往非常模糊，此外如貝多芬等作家作品跨越於古典和浪漫風格，使得音樂對應作曲家-風格學習的難度大幅上升。這導致模型表現出現了決定性的分水嶺 。



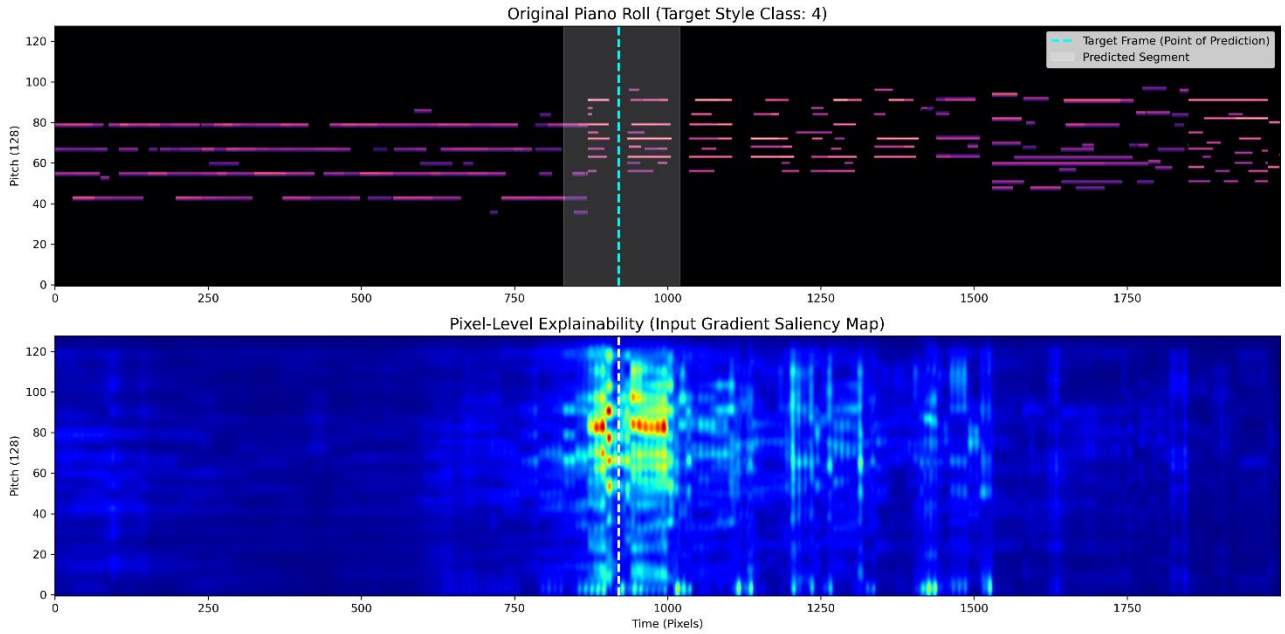
我們將在風格歸因表現最佳的 CRNN+transformers 模型進行多標籤與解釋性實驗驗證：



我們可以從上圖發現模型預測具有以下特色：

1. 音樂片段在開頭與結尾部分信心與準確率較低
2. 短片段的音樂較難準確預測
3. 相近年份或風格相近的作曲家可能會使模型的預測出現錯誤或信心大減

除了將音樂切段進行結構型的合成檢測與風格歸因，我們試圖使用梯度法來進行像素級分析，透過梯度法，我們直接計算**「目標幀的預測 Logit 對輸入鋼琴捲簾的梯度」**。這能精準標示出是哪個音符（哪個像素）促成了該幀的預測，透過梯度影響強弱轉換成熱圖形式。



根據實驗結果，我們可以從熱圖對應原始的鋼琴捲簾中發現音樂領域解釋性具備的兩個特點：

- **物理一致性**：關注區域是否對應真實樂器的基頻與泛音。
- **時序顯著性**：是否關注隨節奏突變或旋律轉折而波動。

將模型的預測預測的區段資訊對照真實標籤”貝多芬(此研究標記為標籤 4)”，我們可以注意到模型的關注區塊集中於**力道較大**(黃色)部分和**短促急收音**上，正好對應貝多芬的有奏風格，**貝多芬**相對於同時期的作曲家**相對多力度起伏較大**，且其演奏的作品中使用了很多**切音**技巧。

由此可知，模型並非瞎猜、或是硬背訓練資料的樂譜資訊，模型準確的捕捉了作曲家的作曲風格資訊，提煉出”作曲家指紋”。

第三方模型生成之音樂辨識測試:

本研究為達到能夠對市面上的 AI 生成音樂進行全面性的辨識的目的，使其具備更全面的泛用性，對抗日益強大的生成式音樂創作模型，本研究額外使用了兩組音樂生成模型作為參考對象分別為 MIDI-LLM 與 MusicGen-medium:

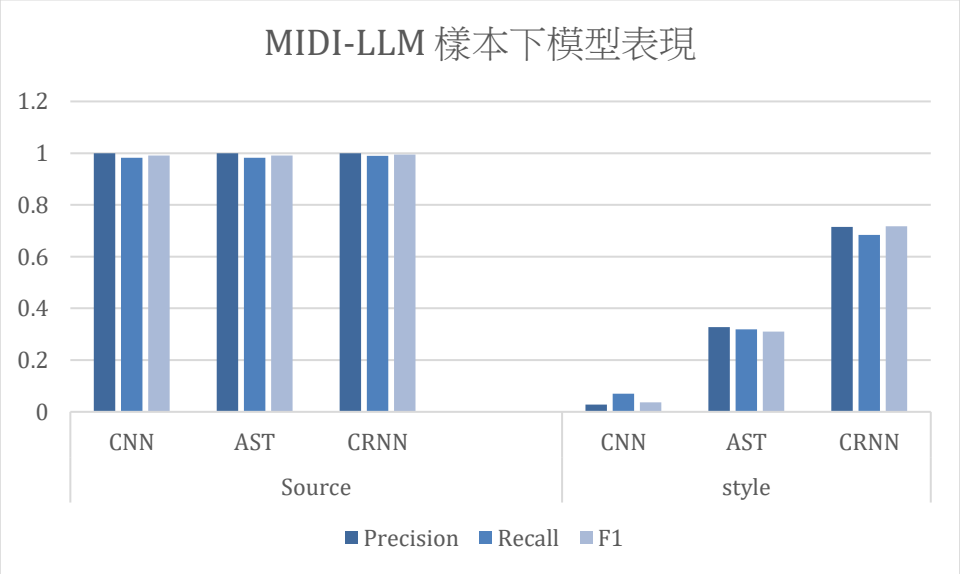
MIDI-LLM：

- MIDI-LLM 是一類將大型語言模型（LLM）架構應用於 MIDI（數位音樂介面） 數據的技術方案，具備強大的結構邏輯能力，擅長捕捉音樂的長程結構（如重複的旋律線或轉調邏輯）。相對於訓練資料集的 MusicGen Large 和 Melody 是更強大更先進的模型，此樣本用於模擬新型、更先進的新開發模型所帶來的衝擊。

	合成檢測			風格歸因		
	CNN	transformers	CRNN	CNN	transformers	CRNN
精確度	1	1	1	0.0283	0.4278	0.7152
F1-score	0.9825	0.9825	0.99	0.07	0.4193	0.6841
Recall	0.9912	0.9912	0.995	0.0361	0.4085	0.7179

從這資料表以及下方整理的長條圖中可以整理出以下資訊：

- **合成檢測(Source，3 類)**：就算是使用 MIDI-LLM 這個結構較為先進的音樂生成模型，三個音樂辨識模型都能在合成檢測中達到接近 100%的精確度，有此可知目前的音樂辨識模型仍然無法完美的”隱藏”其行輸出具有的底層特徵。
- **作曲家與風格歸因 (Composer-Style，21 類)**：在面對新的模型所生成的音樂上，CNN 模型在預測上出現大幅度的能力下滑，AST 表現變化較小，而 CRNN 模型幾乎無明顯的能力下降，我們認為 MIDI-LLM 的音樂生成品質具備甚至超越 MusicGen Large 和 Melody，因此在風格歸因上 CRNN 與 AST 模型的表現才能維持住。



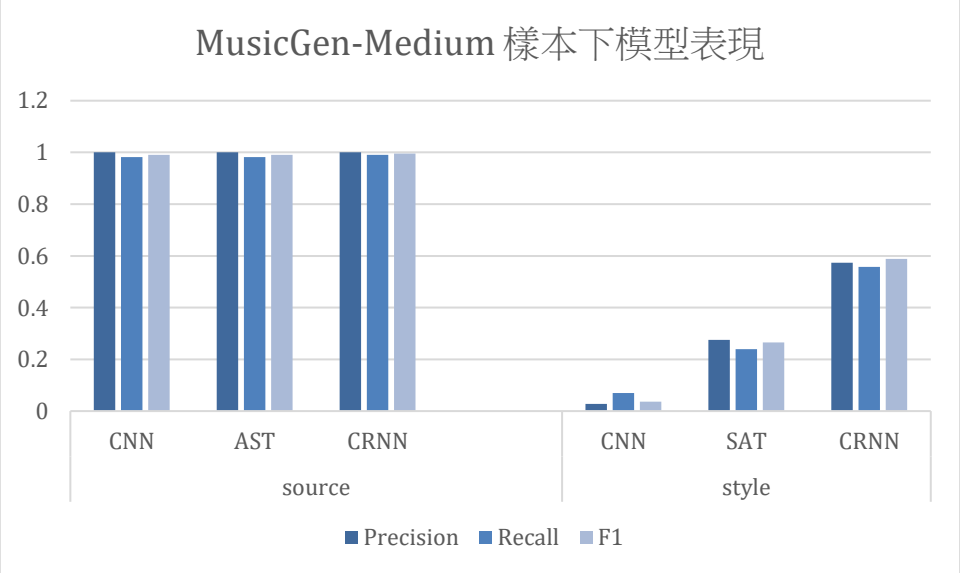
MusicGen-medium：

- MusicGen-medium 是由 Meta AI 開發的音樂生成模型，具有 1.5B 參數。它採用單一階段的 Transformer 架構，相當於訓練資料集中的 MusicGen Large 和 Melody 的弱化版本，製作的音樂較為粗糙，此樣本作為模擬同時期或前期表現較差的模型。

	合成檢測			風格歸因		
	CNN	transformers	CRNN	CNN	transformers	CRNN
精確度	100.00	100.00	100.00	2.83	27.59	57.41
F1-score	98.25	98.25	99.00	7.00	24.00	55.75
Recall	99.12	99.12	99.50	3.61	26.54	58.85

從這資料表以及下方整理的長條圖中可以明顯看出 CRNN 模型在兩個任務中都達到最佳的成績：

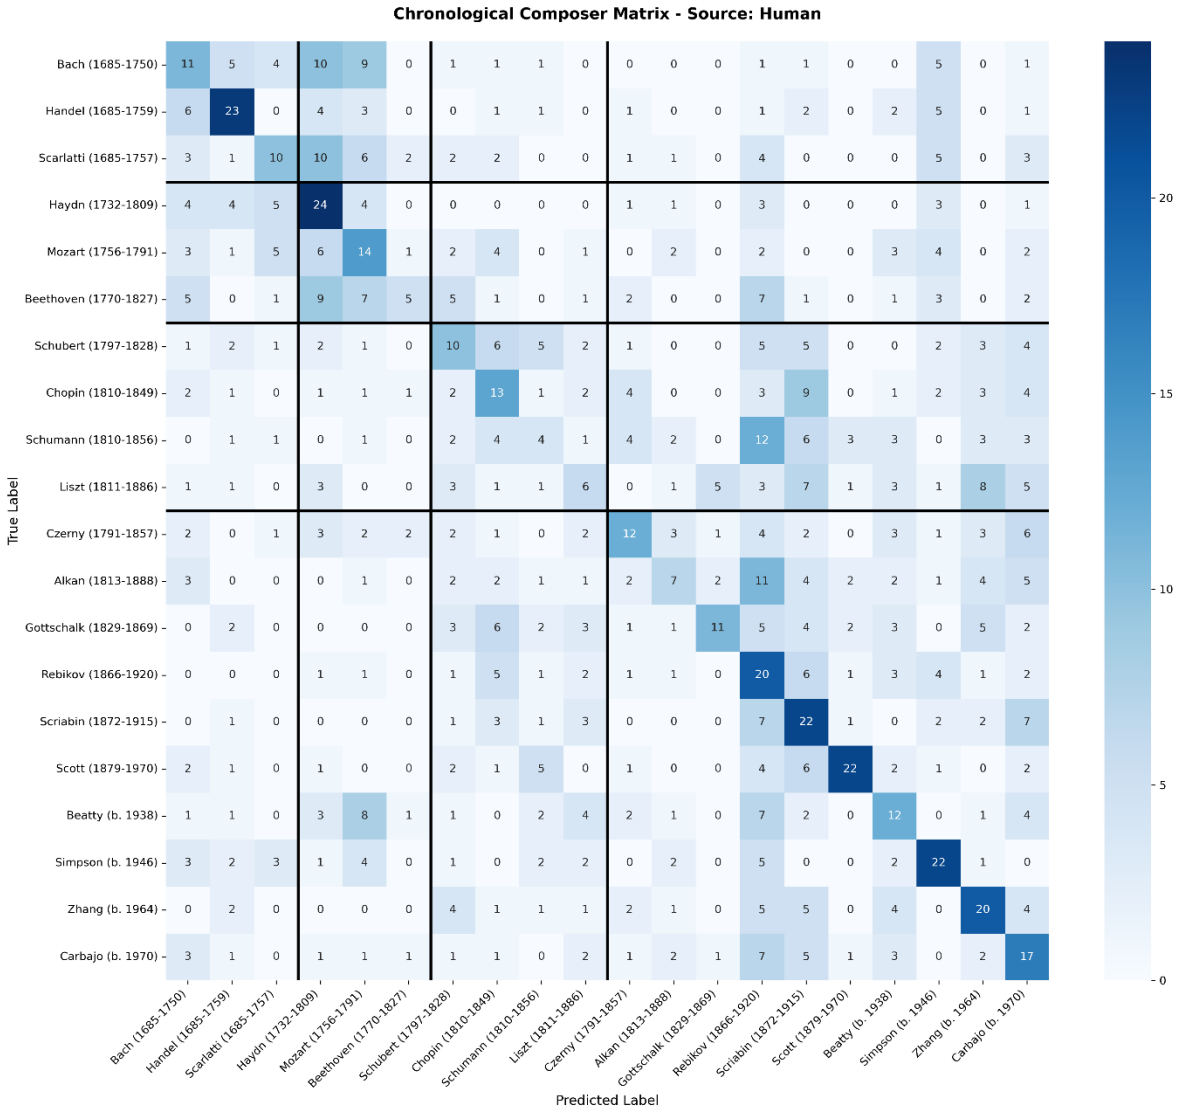
- **合成檢測(Source，3 類)**：這是一個相對簡單的任務。三個模型都能近乎 100 的 F1 分數，且差異不大 。這說明了「MusicGen - medium」在"偽裝"成人類的任務上表現較差，底層音訊或樂理特徵差異較為明顯，因此所有的模型都能辨識出區別。
- **作曲家與風格歸因 (Composer-Style，21 類)**：在面對新的模型所生成的音樂上，三個模型的預測精準度都有大幅度下降的趨勢，其中表現最佳的依然是 CRNN+transformer 模型，在風格歸因中領先 AST 與 CNN 超過 20%的精準度，我們懷疑 MusicGen-medium 的音樂聲成品質不如 MusicGen Large 和 Melody，因此在風格歸因上才會出現大幅度的預測精準度下滑趨勢。



伍、討論

1.風格歸因任務表現對比（Composer-Style Attribution）

由於風格辨識在 CNN 及 AST 模型表現不佳，我們嘗試透過**混淆矩陣(confusion matrix)**解釋音樂辨識上錯誤的可能原因。 下圖為 AST 架構模型進行風格歸因所繪製的混淆矩陣，我們依照作曲家風格的進行切塊，每個風格塊中分別依照生卒年作排列：



從上圖我們可以注意到 模型預測-真實標籤 的結果多數集中於對角線的粗邊大正方形內，由此可知模型具備一定的風格歸因能力，但是礙於 transformer 深度或是參數數量，模型無法更精確的預測到更細微的作曲家特徵，使得”作曲家-風格”表現相對較差。

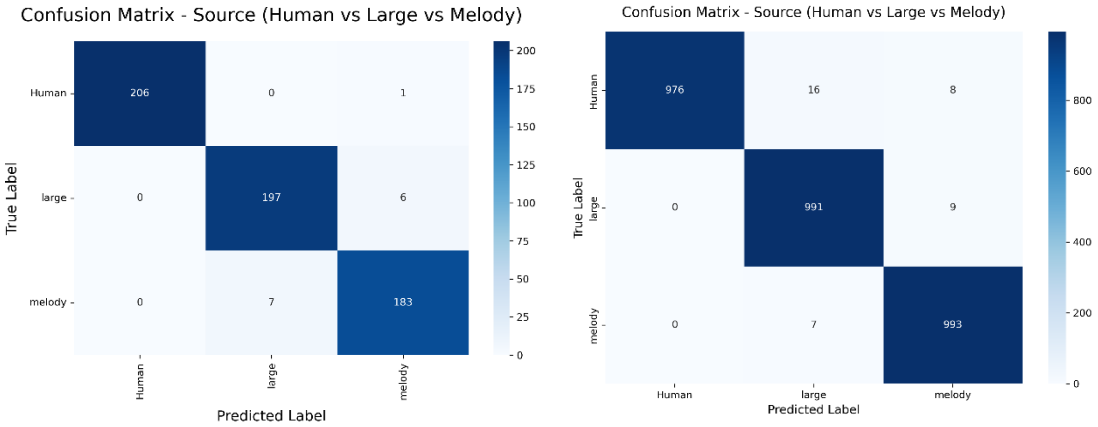
在涉及 20 個類別的「風格歸因」任務中，其中 **CRNN** 則以 **0.7653** 的 F1 分數顯著領先 。CNN 表現低迷的主因在於其主要依賴局部卷積核提取特徵，難以捕捉音樂中跨度極大的旋律走向或和聲配置等非局部（Non-local）長距離關聯 。Transformer 則透過自注意力機制同時關注樂曲各個時間點，使其在處理如 Mozart 與 Haydn 等風格邊界模糊、跨越古典與浪漫時期的作曲家時，能比 CNN 更有效地整合全局資訊 。表現最佳的 **CRNN** 則是因其前端一維卷積（1D CNN）在保留最高解析度音高特徵的同時進行高效時間壓縮 ，並結合 **Bi-LSTM** 的長距

離序列覆蓋優勢與 Transformer 的多尺度特徵融合技術，使模型能同時兼顧淺層樂理特徵（如音符、力度）與深層作曲語意 。

2. 合成分析任務表現對比（Synthesis Analysis）

相較於風格歸因，在「合成分析」任務（區分人類原創與兩類 MusicGen 生成來源）中，三種模型的表現相對均勻且皆維持在高水準，F1 分數介於 **0.927 至 0.928** 之間，彼此差異極小 。這反映出合成檢測屬於難度較低的任務，無論架構為何，模型皆能精確抓取人類作品與 AI 生成音樂之間明顯的底層音訊或樂理特徵差異 。儘管模型在 F1 分數上皆能達到約 **92%**，但仍存在辨識極限，這主要是因為相同的音樂旋律結構可能在不同樣本中重複出現，或 AI 生成音樂帶有微小雜音特性，導致模型在部分樣本上產生誤判 。在此任務中，CNN 的局部特徵提取能力已足以應付分類需求，因此複雜架構（如 CRNN）所帶來的全局時序建模優勢在邊際效益上較不明顯 。

若是有比較 CNN 模型在合成檢測表現優於其他模型，我們懷疑是 AST 和 CRNN 模型的 Focal Loss 在訓練時風格歸因的梯度放大倍數過大到至覆蓋掉合成檢測的梯度資訊，因此在合成檢測的子問題出現過擬合(Overfit)卻無法透過 Focal Loss 的合成梯度進行判斷。



3.與現有研究橫向比較

比較對象	核心目標	解決問題	**模型表現 (F1-score)**	**技術特點**
傳統音樂辨識模型 (如 Shazam)	**音訊匹配**	對應錄音至曲名，資料庫需有完全吻合的樣本	對已知樣本幾乎 100%，對 AI 生成或改作則無法辨識。	僅比對頻譜特徵點，無任何音樂語意分析能力，為**黑盒機制**。
基礎 AI 分類模型 (如 純 CNN/VGG)	**特徵標籤化**	區分曲風或判斷是否為 AI 生成（二元分類）	合成檢測約 0.88-0.92 ；但風格歸因表現極差（約 0.24）。	依賴卷積核抓取局部紋理，難以理解長距離旋律邏輯 。
現有較相近研究 (如 AST)	**視覺風格遷移**	將影像領域的風格歸因概念嘗試引入音訊（多為實驗性）。	風格歸因 F1 約在 0.40 左右，合成檢測則是能達到 0.8 以上。	使用 Transformer 處理全局資訊，但運算負擔重且缺乏對音樂物理特徵的對齊 。
MusicBrain (本研究)	**端到端風格歸因與合成檢測**	解決《著作權法》中「模仿思想」與「重製細節」的灰色斷點 。	**合成檢測 0.927；風格歸因 0.765** ，顯著領先現有架構 。	結合逐幀分析與梯度法，精準提取「作曲家指紋」(如貝多芬的切音）。

陸、結論

本研究成功開發 **MusicBrain** 多指標音樂識別架構，針對 AI 生成音樂（MGMD）提供了兼具精度與透明度的解決方案 。以下為本研究之核心結論：

- **模型表現之優越性**：實驗結果證實，結合 1D CNN、Bi-LSTM 與 Transformer 的 **CRNN 架構** 在複雜的「風格歸因」任務中表現最為卓越，其 F1-score 達 **0.7653**，顯著優於純 CNN 或基礎 Transformer 架構 。
- **任務難度之差異化**：研究發現「合成檢測」屬於底層音訊特徵識別，難度較低（各模型 F1 均達 0.92 以上）；而「風格歸因」涉及深層樂理與作曲語意，是區分人類與高階 AI 的關鍵戰場 。
- **可解釋性之物理意義**：透過梯度法熱圖分析，MusicBrain 成功提取了「作曲家指紋」。以貝多芬作品為例，模型能精準鎖定其標誌性的**力度變化**與**切音技巧**，證明模型決策路徑與音樂物理特徵具有高度一致性 。
- **產業與法律貢獻**：本研究不僅在技術上實現了視覺風格歸因向時頻域的遷移 ，更在實務上為《著作權法》中關於「模仿」與「重製」的灰色地帶提供了量化的判讀依據，有助於數位音樂產業的版權保護與倫理建設 。

柒、未來展望

本研究透過 **MusicBrain** 架構初步驗證了鋼琴捲簾在 AI 音訊識別與風格歸因上的潛力 。然而，面對生成式 AI 術的日新月異，未來本研究將朝以下四個維度持續深耕：

1. 跨樂器編制與聲部結構的普適化

- **多聲部解構**：目前研究範疇聚焦於單一樂器（古典鋼琴）。未來計畫導入「音源分離（Source Separation）」技術，將識別對象擴展至室內樂、管弦樂等具備複雜配器與多層次聲部（Polyphony）的音樂作品，驗證模型在多軌訊號下的穩定性 。
- **跨時空風格遷移檢測**：探討模型是否能有效識別「古典作曲家風格被遷移至現代爵士或流行樂」之跨領域侵權現象，進一步測試風格指紋的邊界。

2. 多模態融合與人聲特徵的整合

- **人聲與合成音效**：針對當前 AI 歌聲合成（AI Singing Voice Synthesis）技術的爆發，未來將納入人聲、合成器音效與電子音色分析 。透過分析共振峰（Formants）與微細顫音規律，區分人類歌手與 AI 擬真語音的特徵差異。

3. 從物理特徵到語意理解的 XAI 演進

- **可解釋性的語意化**：目前的 XAI 主要是基於像素級別的梯度分析（Saliency Map）。未來希望能將熱圖特徵與具體的樂理術語（如：特定的轉調習慣、和弦進行、不協和音程處理）進行映射，讓模型的預測不僅具備物理意義，更能提供音樂理論層面的判讀報告 。

4. 自動化版權監測系統之實證

- **產業應用落地**：因應每日高達 50,000 首的 AI 音樂上傳量，本研究致力於將模型輕量化，研發可供串流平台使用的「自動化版權預警 API」 。
- **法律證據力提升**：透過量化的風格歸因權重，為《著作權法》中的「非法改作」提供更科學、客觀的判讀依據，協助原創者在 AI 時代捍衛數位資產 。

捌、參考文獻資料

- Spotify. (2025, September 25). Spotify strengthens AI protections for artists, songwriters, and producers. Spotify Newsroom.
- Deezer, & Ipsos. (2025, November 12). Deezer and Ipsos study on AI-generated music perception. Deezer Press.
- 中華民國經濟部智慧財產局（2023）。《著作權法》
- Yu, Y., Wang, X., & Yang, Y. H. (2020). GiantMIDI-Piano: A large-scale MIDI dataset for classical piano music.
- Copet, J., Kreuk, F., Gat, I., Talmant, N., Jade, D., & Adi, Y. (2023). Simple and Controllable Music Generation. (MusicGen Model)
- Silva, et al. (2024). ArtBrain: Style Attribution and Explainability in Visual Arts. (借鑒套件)
- Gong, Y., Chung, Y. A., & Glass, J. (2021). AST: Audio Spectrogram Transformer. arXiv preprint arXiv:2106.01797.
- Lin, T. Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. Proceedings of the IEEE international conference on computer vision, 2980-2988.
- Loshchilov, I., & Hutter, F. (2017). Decoupled weight decay regularization. arXiv preprint arXiv:1711.05101.
- McFee, B., et al. (2015). librosa: Audio and music signal analysis in python. Proceedings of the 14th python in science conference.
- Raffel, C., & Ellis, D. P. (2014). Intuitive Analysis of Large MIDI Datasets with pretty_midi. ISMIR.

九、附錄

由於本實驗在架構上以及任務上均與論文中所提供的參考略有差異，因此在分類頭以及輸出平滑以及訓練方式有稍作調整，下方為 CNN 模型與 AST 模型的架構與訓練方式：

1. CNN+Attention 模型：

架構概述 (Architecture Overview)

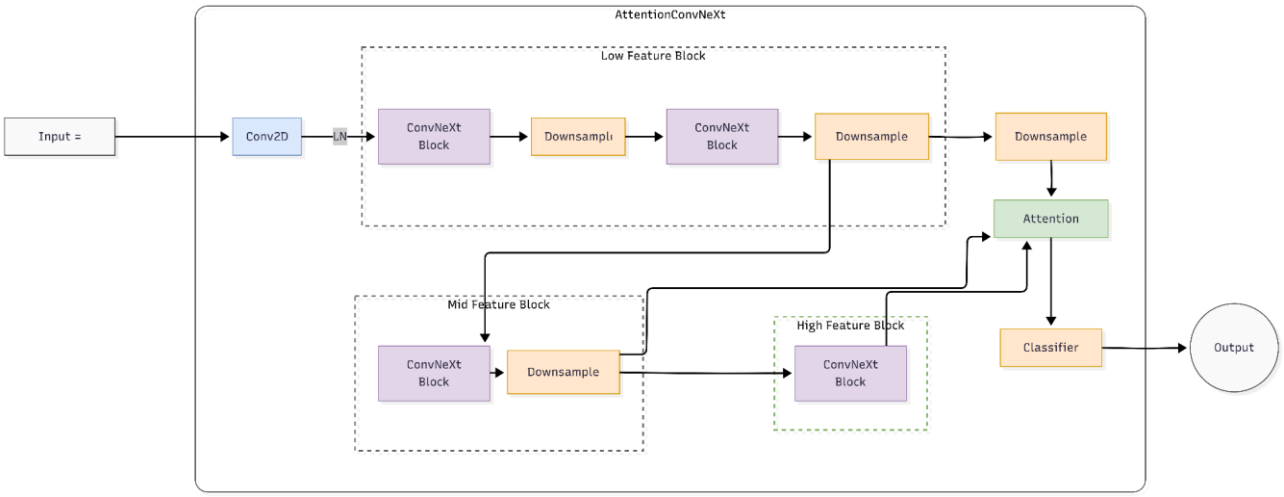
本研究設計並實作了一款基於二維卷積神經網路（2D CNN）的深度學習架構。 該模型專為處理具備空間與時間特性的二維訊號矩陣所打造。整體網路架構遵循 VGG-style 堆疊設計邏輯，主要由「深度卷積特徵提取器（Feature Extractor）」與「全連接分類器（Classifier）」兩大核心區塊組成，旨在從高維度的時頻矩陣中逐層萃取抽象特徵，最終完成 60 個目標類別的多分類任務。

核心模組詳述 (Detailed Module Description)

1. **深度卷積特徵提取模組 (Deep Convolutional Feature Extractor)**
   為了有效捕捉時頻特徵的局部紋理與全局輪廓，特徵提取器由 5 個連續的卷積區塊（Convolutional Blocks）串聯而成。每一個區塊皆包含標準的特徵降維與活化流程：
   - 卷積層 (`Conv2d`)： 皆採用 3×3 大小的卷積核。隨著網路加深逐步提取更深層次的語意特徵。
   - 最大池化層 (`MaxPool2d`)： 每個區塊末端配置 2×2、的最大池化層，將空間維度（時間長度與頻率高度）逐層減半，藉此擴大感受野並過濾冗餘資訊。
2. **全局平均池化層 (Global Average Pooling, GAP)**
   在第 5 個卷積區塊之後，模型使用自適應全局平均池化層。該層將高維度的張量進行壓縮，並大幅減少了後續全連接層的參數負擔。
3. **全連接分類器與正則化 (Fully Connected Classifier & Regularization)**
   經過特徵提取與 GAP 濃縮後的 512 維特徵向量，會被送入由兩層線性層構成的分類器中。特徵經過最後一層的線性轉換後，將輸出對應 num_classes（分為 60 類）的未標準化預測邏輯值（Logits），供後續損失函數進行計算與分類。

CNN+Attention 模型訓練方式

這個模型使用了最標準、基礎的深度學習圖像/音訊分類訓練流程。



- **損失函數**：採用 `CrossEntropyLoss`，並加入 `label_smoothing=0.1` 以防止模型對訓練集產生過度自信（Overconfidence），有助於提升泛化能力。
- **優化器與排程**：使用 `AdamW` 優化器（`weight_decay=0.01`）（Loshchilov & Hutter, 2017）搭配 `CosineAnnealingLR` 餘弦退火學習率排程。
- **特殊評估**：預測出單一 ID 後，利用自訂的 `calculate_metrics` 函數去反查字典 (`dataset_info`)，藉此分離出 `source`（來源）與 `style`（風格）的獨立準確率。

- **時序雙分支 AST(Temporal Dual-Head AST)：**

核心模組詳述 (Detailed Module Description)

本研究提出一種輕量化的「時序雙分支 Transformer」架構（Temporal Dual-Head Transformer），專為處理具備時序延展性之二維特徵(本研究的時頻譜就是其中一個例子)所設計，採用「單一編碼器、雙任務預測頭」的設計架構，能夠從輸入序列中同時提取特徵，並針對「來源（Source）」與「作曲家-風格（Composer-Style）」兩個不同的目標進行多任務學習（Multi-task Learning）。

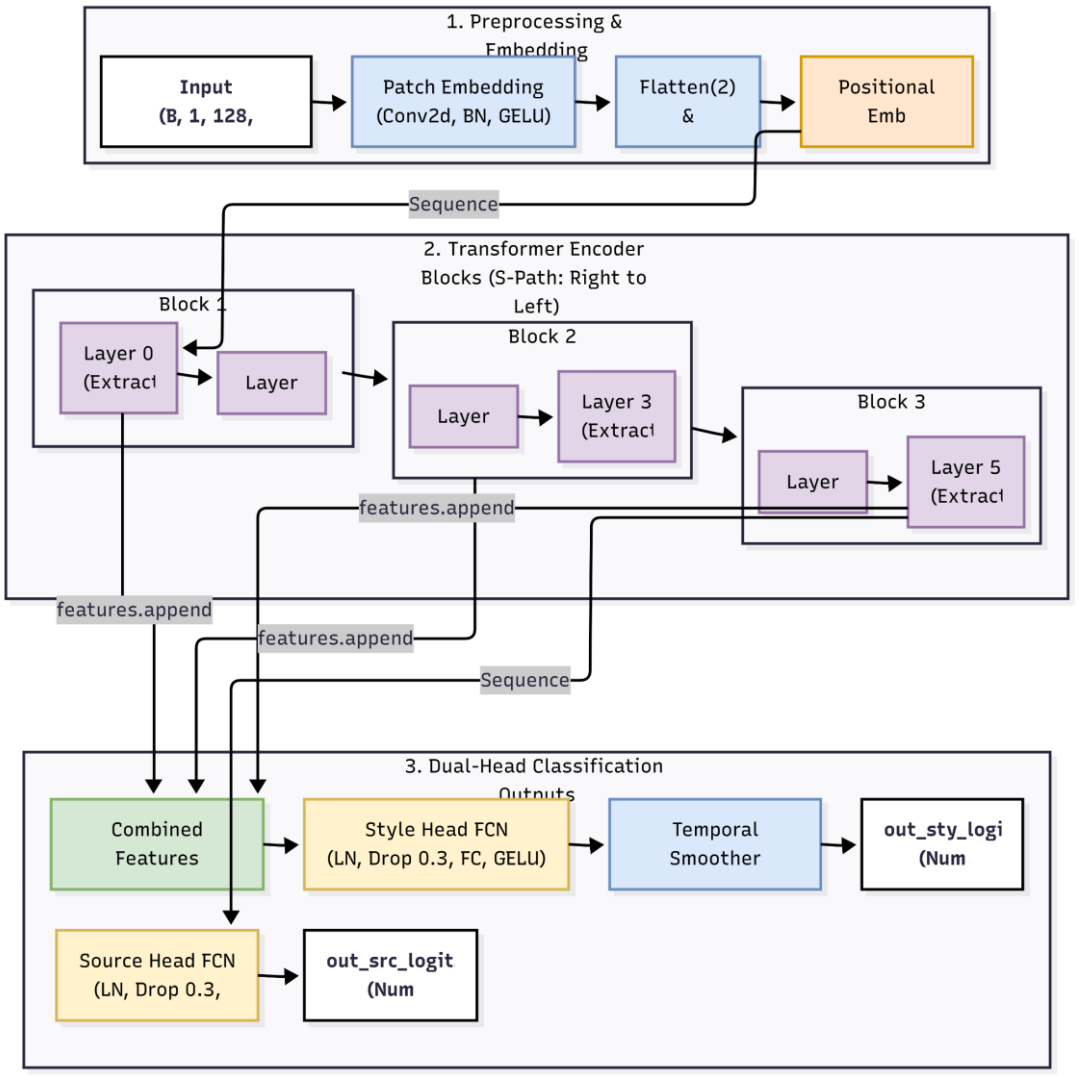
架構概述 (Architecture Overview)

模型由前處理嵌入、核心編碼器，以及雙分支輸出頭三個主要階段構成：

1. Patch Embedding
   模型首先透過特殊設計二維卷積層(`kernel_size` 與 `stride` 皆設定為 `(128,1)`)將單通道的二維輸入特徵轉換為一維序列。此設計在鋼琴捲簾上進行全局特徵壓縮，而在寬度維度（時間軸）上以 10 pixal(0.1 秒) 為步幅進行切片提取。轉換為序列長度為 T、特徵維度（d_{model}）為 128 的時序特徵向量。
2. 位置編碼與 Transformer 編碼器 (Positional Encoding & Transformer Encoder)
   核心編碼器由多層 Transformer Encoder 堆疊而成。每層包含 4 個多頭自注意力機制（Multi-Head Self-Attention, `nhead=4`）與前饋神經網路。為提升在輕量化網路下的泛化能力，內部採用 GELU 作為激活函數。
3. 雙分支預測頭 (Dual-Head Predictors)
   特徵經過編碼器後，會分流至兩個獨立的全連接預測頭，分別執行不同的時序分類任務：
   a. 來源預測分支 (Source Head)：
      此分支結構較為簡潔，直接接收最後一層 Transformer 的輸出特徵。經過線性層直接映射為 num_sources（3 類，Human/AI-melody/AI-large）個類別的預測邏輯值。
   b. 風格預測分支(composer-Style Head)：
      為捕捉更豐富的語義，此分支採用了跨層特徵融合（Cross-layer Feature Fusion）的策略。模型同時抽取了編碼器淺層、中層與深層的輸出並在特徵維度上進行拼接（Concatenation）。此舉能使網路同時兼顧局部細節與全局語義。融合後的特徵經過兩層全連接層分類，輸出 num_styles（預設為 21，20 類的 composer-style 標籤以及一個”無特徵”除錯標籤）個類別。

4. 時序平滑器 (Temporal Smoother)：
   針對風格預測的輸出，模型創新地引入了一維深度可分離卷積（Depthwise Conv1D）作為時序平滑器。此平滑器沿著時間軸對每一個風格類別的預測機率進行滑動濾波，有效抑制預測結果在時間序列上的突變與高頻噪聲，提升時序預測的穩定

性。



時序雙分支 AST(Temporal Dual-Head AST)訓練方式：

引入 Focal Loss 為解決風格歸因相對合成檢測較難分類的問題，針對 Style 任務實作了 `FocalLoss(gamma=2.0)`（Lin 等人, 2017）。這能讓模型自動降低簡單樣本的權重，專注於預測錯誤的困難樣本。